

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ «ЛЭТИ»
ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра алгоритмической математики

ОТЧЁТ
по практической работе №3
по дисциплине «Статистический анализ»
Тема: Обработка выборочных данных.
Нахождение интервальных оценок параметров распределения.
Проверка статистической гипотезы о нормальном законе
распределения

Студент гр. 9372

Иванов Р. С.

Преподаватель

Сучков А. И.

Санкт-Петербург
2021

Цель работы

Получение практических навыков вычисления интервальных статистических оценок параметров распределения выборочных данных и проверки «справедливости» статистических гипотез.

Основные теоретические положения

Определение 1. *Интервальной статистической оценкой* называется интервал (θ_1^*, θ_2^*) , накрывающий с вероятностью γ истинное значение параметра θ , где γ называется *надежностью оценки*.

Алгоритм нахождения доверительного интервала для математического ожидания при неизвестном СКО

Будем искать доверительный интервал в виде $x_{\Gamma} \in (\bar{x}_B - \varepsilon, \bar{x}_B + \varepsilon)$. Тогда при наших условиях:

$$\varepsilon = \frac{t_{\gamma} \cdot s}{\sqrt{n}},$$

где s - несмещенная оценка σ_B ; $t_{\gamma} = t(\gamma, n)$ - константа распределения Стьюдента.

Алгоритм нахождения доверительного интервала для оценки СКО

Возьмем $q = q(\gamma, n)$ - табличное значение. Тогда

$$\sigma_B \in \begin{cases} q < 1, & (s - sq, s + sq) \\ q > 1, & (0, s + sq), \end{cases}$$

где s - исправленное СКО.

Критерий χ^2 Пирсона. Алгоритм для нормального распределения.

Пусть m_i - эмпирические частоты, тогда назовем *теоретическими частотами* числа $m'_i = n \cdot p_i$, где n - объем выборки, p_i - точечная вероятность варианты x_i дискретной случайной величины.

Алгоритм действий

1. Вычислить точечные вероятности p_i . Для расчета попадания случайной величины X в интервал $(x_{i-1}, x_i]$, используем функцию *Лапласа*:

$$p_i = P\{x_{i-1} < X \leq x_i\} = \Phi\left(\frac{x_i - x_B}{\sigma}\right) - \Phi\left(\frac{x_{i-1} - x_B}{\sigma}\right)$$

2. Вычислить выравнивающие(теоретические) частоты m_i .
3. Найти статистику $\chi^2_{\text{набл}} = \sum_{i=1}^k \frac{(m_i - m'_i)^2}{m'_i}$
4. Определить число степеней свободы по формуле $l = k - 3$, где k - число частичных интервалов выборки.
5. По таблице найти критическую величину $\chi^2_{\alpha;l}$, где α - заданный уровень значимости.
6. Сделать выводы. Если $\chi^2_{\text{набл}} < \chi^2_{\alpha;l}$, то закон теоритического распределения не противоречит опытным данным.

Постановка задачи

Для заданной надежности определить (на основании выборочных данных и результатов выполнения практической работы №2) границы доверительных интервалов для математического ожидания и среднеквадратичного отклонения случайной величины. Проверить гипотезу о нормальном распределении исследуемой случайной величины с помощью критерия Пирсона χ^2 .
Дать содержательную интерпретацию полученным результатам.

Выполнение работы

1.

Найдем доверительный интервал математического ожидания

- при $\gamma = 0.95$:

$$\bar{x} = 50225$$

$$s = 39915$$

$$\varepsilon = 7373$$

$$x \in (42852, 57599),$$

- при $\gamma = 0.99$

$$\varepsilon = 9752$$

$$x \in (40473, 59977)$$

2.

Найдем границы доверительного интервала для СКО

- при $\gamma = 0.95$

$$q_\gamma = 0.143$$

$$\sigma_{\text{в}} \in (34207, 45623)$$

- при $\gamma = 0.99$

$$q_\gamma = 0.198$$

$$\sigma_{\text{в}} \in (32012, 47819)$$

3. Проверка гипотезы о нормальном распределении

Вычислим теоретические частоты:

i	1	2	3	4	5	6	7	8	9
p_i	0.2776	0.2264	0.2783	0.1456	0.0559	0.0138	0.002	0.0001	0.000001
m_i	32	26	32	16.74	6.43	1.59	0.25	0.0214	0.0016

Таблица 1 – Вычисления

Число свободы $l = k - 3 = 9 - 3 = 6$. Вычислим $\chi^2_{\text{набл}}$ и сравним его с табличным значением при $\alpha = 0.05$:

$$\chi^2_{\text{набл}} = 673$$

$$\chi^2_{\alpha;l} = 12.6$$

Значение $\chi^2_{\text{набл}}$ получилось таким большим из-за того что последний элемент m_i очень близок к 0, и при делении последнее слагаемое в $\chi^2_{\text{набл}}$ становится равным 620.

Выводы

В процессе работы мы познакомились с алгоритмами вычисления доверительных интервалов для математического ожидания и среднеквадратичного отклонения. Научились работать с функцией *Лапласа*, проверять гипотезы о выбранном законе распределения для выборки с помощью критерия Пирсона.

По найденному значению $\chi^2_{\text{набл}}$ можно смело отвергнуть гипотезу о нормальном распределении выборки.

ПРИЛОЖЕНИЕ А

```
1 # import numpy as np
2 # from nltk.probability import FreqDist
3 # import matplotlib.pyplot as plt
4 import math
5 import csv
6 # import scipy
7 import random
8 # from openpyxl import Workbook
9 # from openpyxl.drawing.image import Image
10
11 sample = []
12
13 with open('Price-Mileage.csv') as csv_file: # Читаем
    выборку из файла 0 работы
14     spam_reader = csv.reader(csv_file, quotechar='|')
15     for row in spam_reader:
16         x, y = row[0].split(';')
17         if y.isdigit(): sample.append(int(y))
18
19 sample.sort() # Используя встроенную функцию
    сортировки получаем ранжированный ряд
20
21 R = sample[len(sample) - 1] - sample[0] # Размах
22 print("R =", R)
23
24 k = round(1 + math.log2(len(sample))) # Число
    интервалов Формула (Стёрджеса)
25 print("k = ", k)
26
27 h = round(R / k) # Длина интервала
28 print("h =", h)
```

```

29
30 k += 1 # Иначе интервалы не покроют выборку
31
32 x0 = sample[0] - h / 2 # Начало первого частичного
    интервала
33 if x0 < 0:
34     x0 = 0
35
36 print("x0 =", x0)
37
38 interval = []
39 x = x0
40
41 for i in range(k):
42     interval.append([(x, x + h), 0, 0])
43     x += h
44
45 # Получаем интервальный ряд
46 for i in sample:
47     for j in range(k):
48         if interval[j][0][0] < i <= interval[j][0][1]:
49             interval[j][1] += 1
50             break
51
52 for i in interval:
53     i[2] = i[1] / len(sample)
54
55 print(interval)
56
57 middle_int = []
58
59 # Вычисляем середины интервалов
60 for i in range(len(interval)):
61     middle_int.append(interval[i][0][0] + h / 2)

```

```

62
63 n = len(sample)
64
65 Xs = 0 # Выборочное среднее по x
66
67 Dsx = 0 # Дисперсия по x
68
69 s = 0 # СКО по x
70
71 for i in range(n):
72     Xs += sample[i]
73 Xs = Xs / n
74
75 for i in range(n):
76     Dsx += (sample[i] - Xs) ** 2
77 Dsx = Dsx / n
78 d = math.sqrt(Dsx)
79 s = math.sqrt(Dsx) * n / (n - 1)
80
81 TY1 = 1.981 # t гамма для 95% n = 115
82 TY2 = 2.62 # t гамма для 99% n = 115
83 D1 = TY1*s/math.sqrt(n)
84 D2 = TY2*s/math.sqrt(n)
85 LB = Xs - D1
86 LR = Xs + D1
87 LB2 = Xs - D2
88 LB2 = Xs + D2
89 Q1 = 0.143 # q для n=100 95%
90 Q2 = 0.198 # q для n=100 99%
91
92 SLB1 = s - s*Q1
93 SRB1 = s + s*Q1
94 SLB2 = s - s*Q2
95 SRB2 = s + s*Q2

```



```

96
97 # Пункт 3
98
99 laplas_arg = []
100 for i in range(8):
101     laplas_arg.append((interval[i][0][1]-Xs)/d)
102
103 laplas = [-0.5, -0.2224, 0.0040, 0.2823, 0.4279,
            0.4838, 0.4976, 0.4998, 0.499986, 0.5]
104 p = []      # Исправленные частоты
105 for i in range(k):
106     p.append(laplas[i + 1] - laplas[i])
107
108 m = []      # m'
109 for i in range(k):
110     m.append(p[i]*115)
111
112 m2 = []     # (m-m')/m'
113 for i in range(k-1):
114     m2.append(((interval[i][1]-m[i])**2)/m[i])
115
116 ans = sum(m2)      # Последнее слагаемое в сумме
                     # равно 620, за счёт деления 1 на число близкое к 0
117 Xi2 = 12.6

```

Листинг 1 – Исходный код программы